# Big Data Analytics: HW#4

108590450 羅傑 資工三 108590452 林峻霆 資工三

## Programming Exercise in MapReduce

Goal: A MapReduce program for analyzing the check-in records in social networks

Input: Check-in records in social networking site *Brightkite* 

- Time and location information of check-ins made by users
- Friendship network of Brightkite users

Output: results of analysis (to be detailed later)

Detailed analysis including the following subtasks:

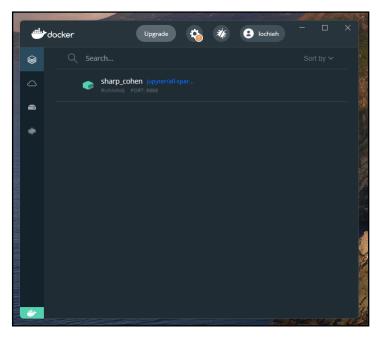
List the top checked-in locations (most popular)

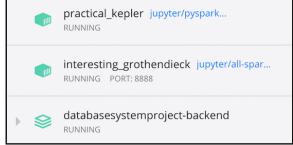
```
In [3]:
import time
start time = time.time()
print("--- %s seconds ---" % (time.time() - start_time))
sc = SparkContext("local", "HM4_2")

# # // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## // ## /
```

## List the top checked-in users

List the most popular time for check-ins (where time is divided into intervals by hours, for example, 7:00-8:00 or 18:00-19:00)





Your cluster environment setup.

## **Dokcer Image Properties**

Name	Tag	IMAGE ID	CREATED	SIZE
jupyter/all-spark- notebook	Latest	0245f58cc2c3	about 1 month ago	4.26 GB
jupyter/all-spark- notebook	Latest	c7a3ce5cab39	3 days ago	3.44 GB

How many PCs (or VMs), hardware spec (CPU cores, memory, storage), network setup, ...





Your source code In folder name HW4.ipynb.

Documentation on how to compile, install, or configure the environment **Windows:** 

## 安裝

您現在可以在系統管理員 PowerShell 或 Windows 命令提示字元中輸入此命令,然後重新開機電腦,安裝執行 Windows 子系統 Linux 版 (WSL) 所需的所有專案。

wsl --install

此命令會啟用必要的選擇性元件、下載最新的 Linux 核心、將 WSL 2 設定為預設值,並根據預設為您安裝 Linux 發行版本 (Ubuntu, 請參閱下方的變更此)。

當您第一次啟動新安裝的 Linux 發行版本時,主控台視窗將會開啟,並要求您等候檔案 解除壓縮並儲存在您的電腦上。 未來的所有啟動時間都應該會低於一秒。

# 在 WSL 2 上開始使用 Docker 遠端 容器

發行項 • 2021/11/28

此頁面有所助益嗎? 凸 🗘

本逐步指南將協助您開始使用遠端容器進行開發,方法是使用 WSL 2 (Windows 子系統 Linux 版第2版) 來**設定適用于 Windows 的 Docker Desktop**。

適用于 Windows 的 Docker Desktop 提供開發環境,可供建立、交付和執行 docker 化應用程式。 藉由啟用 WSL 2 型引擎,您可以在同一部電腦上執行 Docker Desktop 中的 Linux 和 Windows 容器。 (的 docker Desktop 免費供個人使用和小型企業使用,如需 Pro、小組或商務定價的詳細資訊,請參閱Docker 網站常見問題 ②)。

https://docs.microsoft.com/zh-tw/windows/wsl/tutorials/wsl-containers

#### **Docker in Windows:**

- 1. 確認支援Hyper -V
- 2. Docker Hub 進行註冊: https://hub.docker.com/
- 3. 下載Docker



## 4. Docekr架設PySpark



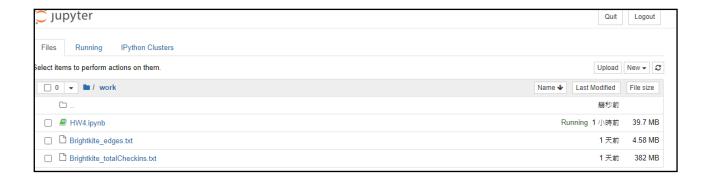
\$ docker pull jupyter/all-spark-notebook
\$ docker run = \$888.8888 jupyter/all spark notebook

\$ docker run -p 8888:8888 jupyter/all-spark-notebook:IMAGEID



## Open file in a browser:

Copy and paste one of these URLs. Start jupyter.



#### **Docker in Mac OS:**

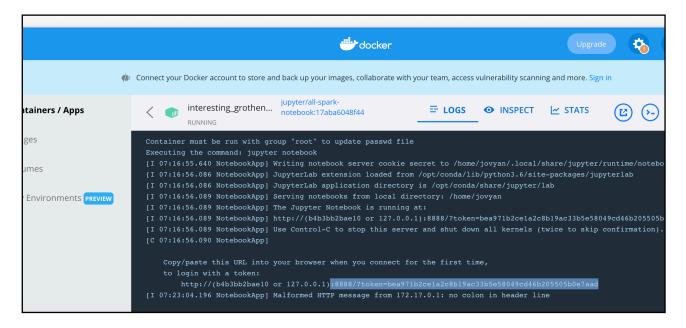
- 1. Docker Hub 進行註冊: https://hub.docker.com/
- 2. 下載Docker



3. Docekr架設PySpark

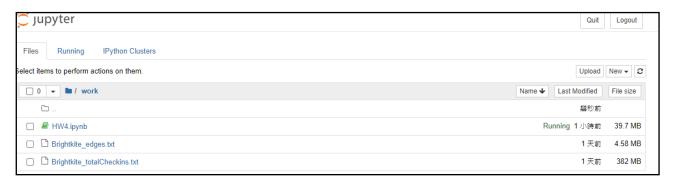


- \$ docker pull jupyter/all-spark-notebook
- \$ docker run -p 8888:8888 jupyter/all-spark-notebook:IMAGEID



### Open file in a browser:

Copy and paste one of these URLs. Start jupyter.



### The efficiency of implemented algorithm will also be taken into account.

最一開始使用迴圈執行效率不佳,後來使用Spark map .reduceByKey() .sortBy() 和撰寫時間處理字串函數,將算法的時間複雜度降低。

兩台電腦算法執行時間比較

### Macbook pro:

```
(70d8cf44678811de9323003048c10834, 1)
(d68263f86f4b11deaa66003048c10834, 1)
(9f7c05905e7911de9102003048c10834, 1)
(3748d39ca2f711dd85eb003048c0801e, 1)
(d4e293a6aef142f8018f2cf533d5a43e, 1)
(3b3eac1a08572efe2d9cd4594b85582b, 1)
(a1c0f9a853f11dd9072003048c0801e, 1)
(6c461dd83cb311deb47a003048c0801e, 1)
(b448102831aa11de9e7b003048c10834, 1)
--- 113.03600406646729 seconds ---
```

```
(57054, 1)

(57285, 1)

(57319, 1)

(57324, 1)

(57414, 1)

(57432, 1)

(57469, 1)

(57670, 1)

(57806, 1)

(57850, 1)

(57942, 1)

(57987, 1)

(58019, 1)

(58054, 1)

--- 19.108819246292114 seconds ---
```

```
(14:00-15:00, 196438)

(05:00-06:00, 174204)

(13:00-14:00, 170380)

(06:00-07:00, 150076)

(12:00-13:00, 142481)

(07:00-08:00, 135464)

(08:00-09:00, 126108)

(11:00-12:00, 124127)

(09:00-10:00, 120083)

(10:00-11:00, 116923)

(Error, 6)

--- 59.2446813583374 seconds ---
```

#### Windows:

```
(fa139822171311deb4e5003048c0801e, 1)
(edd1bed6a22411ddbed663011b1bd08d, 1)
(3d7d14b25e8ac8b547b825c5c095abab, 1)
(d96221c0a22411dd8663b716ce2a00d1, 1)
(eedbffeea22411dd8fea23d05d0a1969, 1)
(298c07c2a33a748bdb04c259d68086a505463e58, 1)
(838eb604dfe8eede02bd9a5843454c3c, 1)
(99f4245479ea11de84f3003048c10834, 1)
(70d8cf44678811de9323003048c10834, 1)
(d68263f86f4b11deaa66003048c10834, 1)
(9f7c05905e7911de9102003048c10834, 1)
(3748d39ca2f711dd85eb003048c0801e, 1)
(d4e293a6aef142f8018f2cf533d5a43e, 1)
(3b3eac1a08572efe2d9cd4594b85582b, 1)
(a1c0f9a853f11dd9072003048c0801e, 1)
(6c461dd83cb311deb47a003048c0801e, 1)
(b448102831aa11de9e7b003048c10834, 1)
--- 117.9945616722107 seconds ---
```

```
(57285, 1)
(57319, 1)
(57324, 1)
(57414, 1)
(57432, 1)
(57469, 1)
(57670, 1)
(57806, 1)
(57850, 1)
(57942, 1)
(57987, 1)
(58019, 1)
(58054, 1)
--- 16.8202223777771 seconds ---
```

```
(04:00-05:00, 203366)

(14:00-15:00, 196438)

(05:00-06:00, 174204)

(13:00-14:00, 170380)

(06:00-07:00, 150076)

(12:00-13:00, 142481)

(07:00-08:00, 135464)

(08:00-09:00, 126108)

(11:00-12:00, 124127)

(09:00-10:00, 120083)

(10:00-11:00, 116923)

(Error, 6)

--- 45.372206926345825 seconds ---
```